Data Science

Sergio Santoyo Daniel Fernández

Índice

- 1. Información del Taller
- 2. ¿Qué es data science?
- 3. ¿Por qué el físico es un buen data scientist?
- 4. Ejemplos en la vida real
- Áreas de data science
- 6. ¿Por qué ahora? "Big Data"
- 7. Procesos de data science
- 8. Herramientas
- 9. Experiencias
- 10. Futuras aplicaciones
- 11. Temario talleres
- Notebook 0: "Hola mundo"



Taller:

- Duración: 6 sesiones
 - Sesión 1: Marzo 7
 - Sesión 2: Marzo 14
 - Sesión 3: Marzo 21
 - Sesión 4: Abril 4
 - Sesión 5: Abril 11
 - Sesión 6: Abril 21
- Autores: Sergio Santoyo, Daniel Fernández
- Salón: LPB 12
- Horario: 17 a 19
- Github del taller: https://github.com/ldfo/ds-uia-2018
- Canal de Slack: <u>ds-uia.slack.com</u>

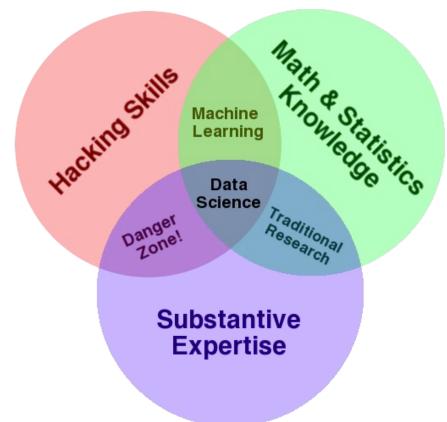
¿Qué es Data Science?

 Ayudar la toma de decisiones por medio de cómputo científico, estadística, probabilidad y visualizaciones.

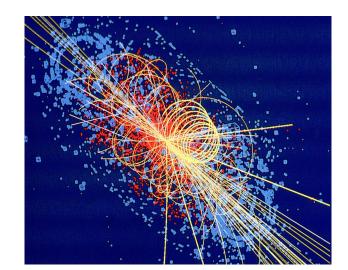
Wikipedia:

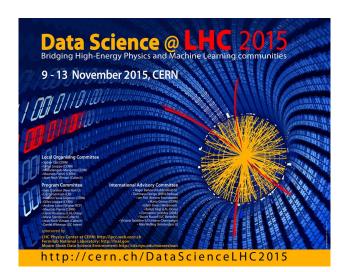
- Also known as data-driven science, is an interdisciplinary field of scientific methods, processes, and systems to extract knowledge or insights from data in various forms, either structured or unstructured, similar to data mining.
- **Data mining** is the process of discovering patterns in large data sets involving methods at the intersection of machine learning, statistics, and database systems. It is an essential process where intelligent methods are applied to extract data patterns. It is an interdisciplinary subfield of computer science.

¿Por qué el físico es un buen data scientist?

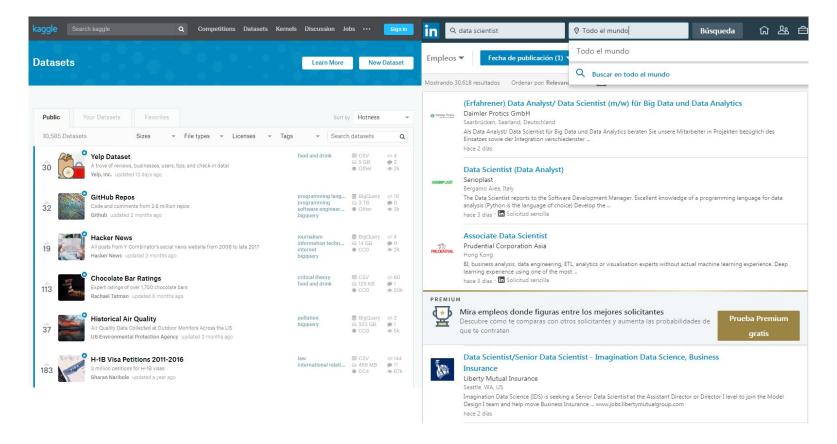


- Miles de años: ciencia empírica, describe fenómenos naturales.
- Cientos de años: ciencia teórica, generando modelos buscando generalizaciones.
- Décadas: ciencia computacional, simulaciones de fenómenos complejos.
- Hoy: ciencia empírica + teórica + computacional.





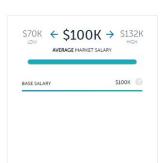
Vida real



The average salary for Data Scientists is \$100K.

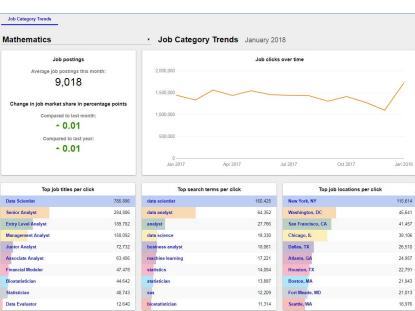
Sign in to see how much you should be making »

A Data Scientist makes an average of \$100K, ranging from \$70K to \$132K based on 16K profiles. These numbers represent our estimate for potential total compensation, including Base Salary, approximate Equity, and an Annual Bonus as an aggregate of all Data Scientist salaries. Explore relevant salary ranges, open jobs, associated skills, demographics insights, and more.





Last Updated on: January 26th, 2018



Áreas de Data Science

Machine Human

Data Management Human Cognition

Data Mining Perception

Machine Learning Visualization Story Telling

Business Intelligence Decision Making
Theory

Statistics

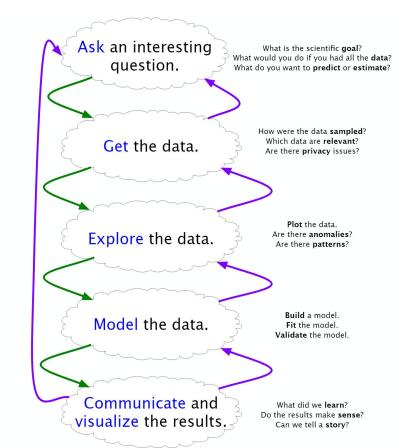
Data Science

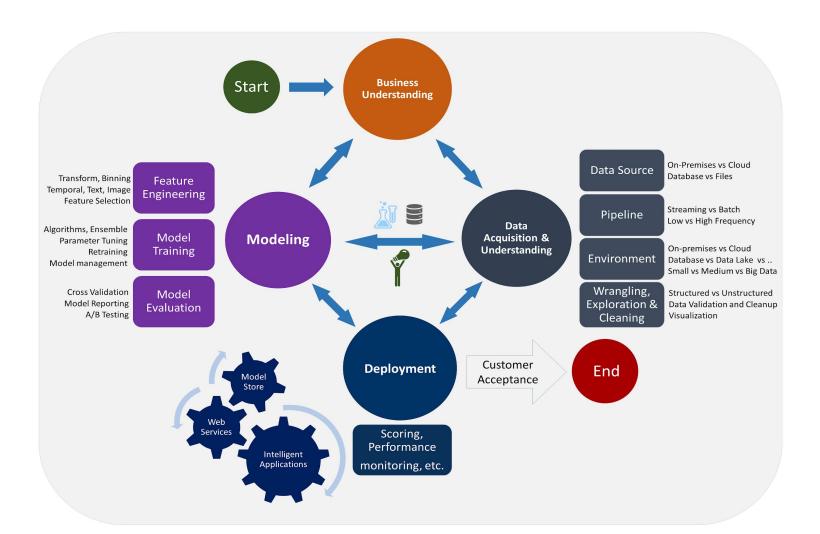
¿Por qué ahora? "Big Data"

- Para el 2020 se estima una generación de datos diaria de 35(10)¹² GB.
- Gran variedad de datos (redes sociales, transacciones, videos, texto).
- 90% de los datos existentes hoy, fueron generados en los últimos 5 años.
- El contenido es generado por bots y por humanos: ~400 millones de tweets diarios.
- Más de 72 horas de video subidas a YouTube cada minuto.
- Aproximadamente 1.4 billones de usuarios diarios de Facebook.
- Internet of things.
- Industry 4.0 / 5.0

BIG DATA = volumen + velocidad + variedad

Procesos de data science



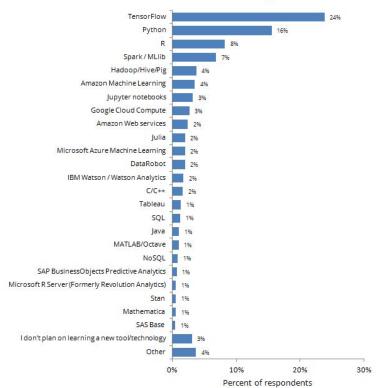


Herramientas

- El 52.6% del desarrollo se hace en Python.
- El 34.9% usan SQL para bases de datos.
- El 52.1% usan R.
- La herramienta depende del objetivo: producto, análisis, reporte, dashboard, etc.
- "No te cases con una tecnología"



Data Science Tool or Technology Data Pros are Most Excited about Learning in 2018



Data are from the Kaggle 2017 The State of Data Science and Machine Learning study. You can learn more about the study and download the data here: https://www.kaggle.com/surveys/2017.

Respondents were asked to indicate which tool or technology they are most excited about learning in the next year. A total of 10098 respondents answered the question. Tools and technologies that were selected by less than 1% of the survey respondents are not included in the graph.









Store Data









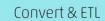
















99000

























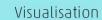
elasticsearch. AKNIME



















































Experiencias

Sergio:

- Intelimétrica: Real estate, desarrollar modelos, pipelines de procesamiento y manutención de bases de datos. Desarrollo de proyectos para clientes. Detección de anomalías, modelos de valuación automática, pipelines de procesamiento, proyecto de índice de valor patrimonial.
- Abraxas Intelligence: Consultoría a grupo Bimbo, análisis de series de tiempo de accidentes laborales, análisis de texto de reportes de accidentes laborales, generación de reportes.
- Sinnia: Redes sociales, inferencia de edades de usuarios de Twitter, clasificación de textos de noticias, análisis de polaridad política para candidatos a la presidencia, clustering de series de tiempo de trending topics para Twitter. Deployment y manutención de modelos en la nube.

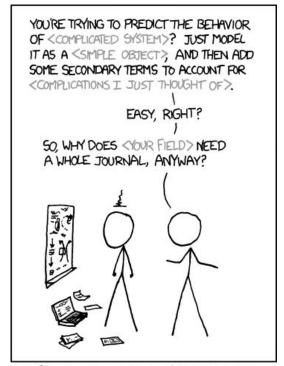
Daniel:



Temario:

- Introducción al taller
- 2. Manipulación y visualización de datos
- 3. Regresión lineal
- Problemas de clasificación
- 5. Aprendizaje supervisado
- 6. Aprendizaje no supervisado y técnicas avanzadas

Notebook 0: "Hola Mundo"



LIBERAL-ARTS MAJORS MAY BE ANNOYING SOMETIMES, BUT THERE'S NOTHING MORE OBNOXIOUS THAN A PHYSICIST FIRST ENCOUNTERING A NEW SUBJECT.

